Autorzy: Marek Górski, Łukasz Stajkowski

LENS: Learning Ensemble Confidence from Neural States for Multi-LLM Answer Integration

Ograniczenia

- LLM
- Sprzęt
  - AMD Radeon RX 7900XTX
  - Platforma ROCm

Modele

- unsloth/Llama-3.2-1B-Instruct
- ai-nexuz/llama-3.2-1b-instruct-fine-tuned
- NousResearch/Hermes-3-Llama-3.2-3B
- keeeeenw/Llama-3.2-1B-Instruct-Open-R1-Distill
- EpistemeAI/Reasoning-Llama-3.2-1B-Instruct-v1.2

Jak to działa?

- Ensembling na tokenie
- CMLP(Confidence Multi-Layer Perceptron)

Benchmarki

google/boolq	train[:2000]	rozumowanie binarne (tak/nie)
smoorsmith/prontoqa	train[:500]	wieloetapowa logika
skrishna/coin_flip	train[:2000]	spójność probabilistyczna
tasksource/proofwriter	train[:2000]	strukturalne dowodzenie

Rezultaty (dokładność %)

Model\Dataset	boolq	coin_flip	prontoqa	proofwriter
Ensemble	60.5	47.0	42.5	83.0
Hermes-3-Llama-3.2-3B	53.0	47.0	42.5	53.0
Llama-3.2-1B-Instruct	61.5	47.0	60.5	68.0
Llama-3.2-1B-Instruct-Open-R1-Distill	55.5	55.5	27.0	92.5
Reasoning-Llama-3.2-1B-Instruct-v1.2	60.0	47.0	12.5	70.5
llama-3.2-1b-instruct-fine-tuned	61.5	47.0	50.0	61.5

Prezentacja działania

Dziękujemy za uwagę